PROYECTO FINAL: MODELADO PREDICTIVO DE CLASIFICACIÓN Y PIPELINE DE DATOS

Programación Avanzada en Ciencia de Datos — Licenciatura en Ciencia de Datos

En el marco de la asignatura Programación Avanzada en Ciencia de Datos, se presenta la consigna oficial del Proyecto Integrador Final. El objetivo central es que los estudiantes diseñen e implementen una solución punta a punta (*end-to-end*) aplicando buenas prácticas de programación modular, control de versiones, integración con bases de datos y desarrollo de modelos predictivos de clasificación mediante scikit-learn.

1. OBJETIVO Y DATASETS DISPONIBLES

Cada estudiante o equipo deberá elegir **uno** de los siguientes tres datasets públicos y gratuitos en Argentina / CABA para desarrollar un modelo predictivo de **clasificación binaria o multiclase**:

- **Opción A - Mercado Inmobiliario y Tipificación de Propiedades (CABA):**
  Dataset: Departamentos en Venta (Portal de Datos Abiertos de la Ciudad de Buenos Aires - BA Data).
  Objetivo: Predecir la categoría o segmento de valor del departamento según precio publicado, superficie, antigüedad, ambientes y ubicación.
  Enlace: https://data.buenosaires.gob.ar/dataset/departamentos-venta
- **Opción B - Demanda y Consumo de Energía Eléctrica:**
  Dataset: Demanda de electricidad (Datos Argentina; fuente primaria CAMMESA).
  Objetivo: Clasificar períodos de demanda alta o crítica frente a demanda normal según demanda total y sectorial, temperatura, potencia máxima y estacionalidad.
  Enlace: https://datos.gob.ar/dataset/sspm-demanda-electricidad
- **Opción C - Riesgo y Mora en Garantías para MiPyMEs:**
  Dataset: Sociedades de Garantía Recíproca (SGR), recurso 03-Mora (Datos Argentina).
  Objetivo: Clasificar períodos o entidades por nivel de mora según montos, cantidad de garantías y MiPyMEs en mora, plazos de atraso y composición del financiamiento.
  Enlace: https://datos.gob.ar/dataset/produccion-sociedades-garantia-reciproca-sgr

2. REQUERIMIENTOS TÉCNICOS Y ARQUITECTURA

El desarrollo del proyecto debe cumplir rigurosamente con los siguientes aspectos técnicos:

1. **Construcción del Modelo (scikit-learn):** Implementar un sklearn.pipeline.Pipeline para el preprocesamiento (imputación, escalado, codificación de categóricas). Comparar al menos dos algoritmos de clasificación (ej. *Logistic Regression, Random Forest, XGBoost*) y optimizar hiperparámetros con GridSearchCV o RandomizedSearchCV.
2. **Evaluación de Desempeño:** Evaluar los modelos utilizando las métricas: **Accuracy, Precision, Recall y F1-Score**, acompañadas por la Matriz de Confusión correspondiente.
3. **Almacenamiento e Integración con Base de Datos:** Persistir la información en una base de datos relacional (SQLite, PostgreSQL) o NoSQL (MongoDB). La BD debe incluir:
    - **Tabla 1:** Datos de entrada limpios y preprocesados.
    - **Tabla 2:** Resultados del modelo (predicciones y métricas globales).
    - **Tabla 3 (Opcional - Extra):** Configuración y parametrización del modelo.
4. **Visualización:** Presentar gráficos y tablas claras utilizando matplotlib, seaborn, Plotly, Power BI o Streamlit.

3. RÚBRICA DE EVALUACIÓN Y ENTREGABLES

Criterio	Peso	Descripción
Buenas prácticas de código y Git	25%	Organización del proyecto, calidad del código (PEP 8), uso de funciones y clases, comentarios y control de versiones en Git/GitHub.
Base de datos y visualización	25%	Integración correcta de BD para almacenamiento de datos de entrada/salida y uso de visualizaciones claras y efectivas.
Modelado y resultados	25%	Claridad al explicar el flujo de trabajo, decisiones técnicas y justificación metodológica

Criterio	Peso	Descripción
		de métricas.
Presentación oral y defensa	25%	Exposición de 8 a 10 minutos, claridad, dominio del tema, uso de material visual y manejo del tiempo.

Formato de Entrega

- **Repositorio Git:** Código fuente estructurado, script de carga a BD, requirements.txt o environment.yml y README.md.
- **Base de Datos:** Accesible para la revisión.
- **Presentación:** Diapositivas (6 a 8 filminas) en formato PDF o PPTX subido al campus virtual.